

CUDA. Laboratorium 3.

W tym ćwiczeniu uruchamiamy w CUDA klasyczny program mnożenia macierzy w trzech, a nawet czterech wariantach. Naszym zadaniem jest porównanie czasów wykonania i wyjaśnienie elementów kodu.

W dalszym ciągu korzystamy ze środowiska google colab, przygotowanego tak jak w poprzednich ćwiczeniach.

Każdy z programów proszę uruchomić dla trzech różnych rozmiarów macierzy kwadratowych – domyślnie jest to 1024 x 1024. Wynik dla takiej trójki wartości proszę przedstawić w formie tabelki, albo wykresu słupkowego lub innego.

1. Algorytm z wykorzystaniem pamięci globalnej

Jest użyty w programie `matrixmul.cu`. Kernel mnoży skalarnie jeden wiersz macierzy przez jedną kolumnę.

Proszę odpowiedzieć na pytanie czy w kernelu zachowany jest dostęp łączony?

Proszę też odpowiedzieć, dlaczego liczba bloków (zmienna `gridDim`) jest wyznaczana za pomocą takiego trochę dziwnego wzoru? A przy okazji co to jest `dim3` ?

2. Algorytm z wykorzystaniem pamięci współdzielonej.

Drugie podejście zakłada wykorzystanie pamięci współdzielonej. Dokonuje się tu podziału na kafelki (tiles), będące kwadratowymi blokami o rozmiarze `TILE_DIM`. Proszę skomentować, dlaczego `TILE_DIM` jest równe `blockDim`. Jaka może być największa wartość `blockDim`?

Proszę odczytać jaki jest czas wykonania. Proszę sprawdzić czy wyniki są poprawne. Proszę też ocenić czy w kernelu dochodzi konfliktu w dostępie do banków pamięci.

3. Algorytm z wykorzystaniem biblioteki cuBLAS (w dwóch wariantach)

Ostatnia wersja programu wykorzystuje bibliotekę cuBLAS. W pierwszym wariantcie, `matrixmul_cublas.cu`, wywołanie jest dokonane wprost. W drugim, `matrixmul_cublas_speed.cu`, zostały dokonane drobne modyfikacje. Proszę odczytać czasy w obu wariantach i krótko skomentować modyfikacje. W szczególności proszę sprawdzić w sieci na czy polega proces *warm-up* i jak wpływa na czas wykonania.