


Konfiguracja klastra Elastic Map Reduce w chmurze AWS


Po zalogowaniu się do AWS Academy i przejściu do kursu, przechodzimy do laboratorium “Lab: Processing Logs by Using Amazon EMR”, uruchamiamy Lab i przechodzimy do konsoli AWS.

1. Przechodzimy do usługi EMR:



2. Tworzymy klaster

Po kliknięciu w Create cluster:



- Wybieramy opcję “**Core Hadoop**”
- W sekcji **Cluster logs** wyłączamy “Publish cluster-specific logs to Amazon S3”
- W **Amazon EMR Service role** ustawiamy “EMR_DefaultRole”
- W **EC2 instance profile for Amazon EMR** wybieramy “EMR_EC2_DefaultRole”
- **Amazon EC2 key pair for SSH to the cluster** ustawiamy na “vockey” (klucz prywatny można pobrać z konsoli AWS Academy)
- **Uwaga:** do obliczeń używamy węzłów typu **Core** (na których jest również system HDFS). Opcjonalnie można zmienić ich liczbę.
- Reszta konfiguracji może zostać domyślna

Name


MPR_cluster

Amazon EMR release [Info](#)

A release contains a set of applications which can be installed on your cluster.

emr-6.10.0

Application bundle



3. Finalizujemy klikając **Create cluster**

MPR_cluster


Updated less than a minute ago

Actions

▼ Summary

Cluster info	Applications	Cluster management	Status and time
Cluster ID j-1C84Y3S6004JY	Amazon EMR version emr-6.10.0	Log destination in Amazon S3 Logging not configured	Status Starting
Cluster configuration Instance groups	Installed applications Hadoop 3.3.3, Hive 3.1.3, Hue 4.10.0, Pig 0.17.0, Tez 0.10.2	Primary node public DNS ec2-52-202-47-213.compute-1.amazonaws.com Connect to the Primary Node using SSH	Creation time May 04, 2023, 10:06 (UTC+02:00)
Capacity 1 Primary 1 Core 4 Task			Elapsed time 6 minutes, 42 seconds

Po kliknięciu na “Connect to the Primary Node Using SSH” należy skopiować komendę by połączyć się z węzłem Primary przez SSH. Klucz prywatny ssh należy pobrać z konsoli AWS Academy klikając na *AWS Details*:



Uwaga: może istnieć konieczność dodania reguły dla ruchu SSH w ustawieniach grupy bezpieczeństwa Primary Node

▼ EC2 security groups (firewall)

Primary node

EMR managed security group

[sg-01988b2f52dd232eb](#)

Maszyny klastra można również zobaczyć w **widoku konsoli EC2**

Logujemy się na węzeł Primary:

1. Pobieramy przykładowy plik z danymi wejściowymi

```
$ wget --no-check-certificate
"https://drive.usercontent.google.com/download?id=1smWP13RMS9LwStvM
HNF0wnhTDtLawBS0&confirm=t" -O "gutenberg-500M.txt.gz"
```

2. Kopiujemy dane do HDFS:

```
$ gunzip gutenber-500M.txt.gz
$ hdfs dfs -mkdir books-input
$ hdfs dfs -put *.txt books-input
```

3. Następnie [kopiujemy implementacje mapper.py i reducer.py](#) (najlepiej wget używając linków 'raw'). Alternatywne (bardziej wydajne) implementacje korzystają z generatorów: mapper-adv.py i reducer-adv.py.

Przetestować ich działanie można komenda:

```
$ printf 'aaa bbb ccc\naaa' | ./mapper.py | sort | ./reducer.py
aaa      2
bbb      1
ccc      1
```

4. Uruchamiamy przetwarzania Map Reduce (z pomiarem czasu):

```
$ time hadoop jar /usr/lib/hadoop/hadoop-streaming.jar -files  
mapper.py, reducer.py -mapper mapper.py -reducer reducer.py -input  
books-input -output books-output
```

Inne przydatne komendy:

hdfs dfs -rm -r books-output	Usuwanie katalogu z danymi wyjściowymi
hdfs dfs -get books-output	Pobranie danych wyjściowych
hdfs dfs -ls	Wylistowanie zawartości HDFS

Sprzątanie

Na koniec można ręcznie usunąć klaster, a jeśli się tego nie zrobi to domyślnie po godzinie nieaktywności jest on ręcznie usuwany.