

Oznacz jako wykonane

Wymagane do: wtorek, 19 maja 2026, 20:00

- Do zadania potrzebne będą zbiory danych tekstowych o wielkości 1G, 10G i 20G. Proszę wykorzystać plik [gutenberg-500M.txt.gz](#) (po rozpakowaniu 500M). W celu uzyskania większych danych wystarczy kopiować ten plik odpowiednią liczbę razy.
- Komenda do bezpośredniego pobrania pliku:

```
wget --no-check-certificate "https://drive.usercontent.google.com/download?id=1smWPI3RMS9LwStvMHNF0wnhTDtLawBS0&confirm=t" -O "gutenberg-500M.txt.gz"
```

- Proszę wykonać **jak najbardziej wydajną sekwencyjną implementację algorytmu word count** (język programowania dowolny, ale jego wybór może mieć znaczenie) i zmierzyć czas jej działania dla w/w zbiorów danych. Proszę to zrobić na maszynie EC2 o takim samym typie instancji, jaka będzie używana w klastrze EMR. Może to być węzeł Primary (ale upewnić się, że nie jest on obciążony) lub instancja przygotowana osobno przez usługę EC2.
- Proszę uruchomić te same obliczenia z użyciem Hadoop na klastrze EMR w co najmniej dwóch różnych konfiguracjach o tej samej liczbie rdzeni (np. 2 mocniejsze i 4 słabsze węzły robocze). Proszę wykorzystać tyle rdzeni na ile pozwalają limity. Zmierzyć czas obliczeń.
- Wszystkie pomiary proszę zapisać w jednym pliku CSV o następujących kolumnach:
 - nCores - liczba rdzeni
 - confId - jakiś identyfikator konfiguracji (słabsze węzły / mocniejsze węzły)
 - dataSize - rozmiar danych wejściowych (1, 10G, 20G)
 - time - czas obliczeń
- Korzystając z tego pliku proszę zrobić wykresy średniego czasu obliczeń dla każdego rozmiaru danych wejściowych i konfiguracji (w tym wersja sekwencyjna); polecane narzędzie Pandas+matplotlib - po kolumnach nCores i confId należy zrobić groupBy i dla każdej grupy wyliczyć średni czas - zgodnie z metodą [split-apply-combine](#).
- Czy w którymś przypadku da się określić metrykę COST (wyrażoną liczbą rdzeni)?

Uwagi:

- Proszę pamiętać, że punktem odniesienia (baseline) powinien być czas obliczeń jak najlepszej implementacji sekwencyjnej na pojedynczym węźle.
- Proszę pamiętać o właściwej metodologii pomiaru (kilka pomiarów i obliczenie średniej/stddev - ze względu na ograniczenia wystarczą 2 pomiary)
- Większe dane można umieścić w HDFS kopiując ten sam plik (polecenie `hdfs dfs -put`) wiele razy z jednoczesną zmianą nazwy. Uwaga: proszę upewnić się gdzie na węźle Primary jest odpowiednia ilość miejsca na dane (prawdopodobnie na `/mnt1`).
- Dane mogą być przesyłane na klaster EMR na wiele sposobów, opisanych na [How to get data into Amazon EMR - Amazon EMR](#). W szczególności mogą pochodzić z bucketu S3. Przykład polecenia (z pomiarem czasu):

```
time hadoop jar /usr/lib/hadoop/hadoop-streaming.jar -files s3://elasticmapreduce/samples/wordcount/wordSplitter.py -mapper wordSplitter.py -reducer aggregate -input s3://elasticmapreduce/samples/wordcount/input -output wordcount-output
```

Jako wynik proszę załączyć sprawozdanie z pomiarów przedstawiające parametry mierzonych konfiguracji, wykresy przyspieszenia, odpowiedzi na pytania oraz inne komentarze do wyników. Proszę również dołączyć plik CSV z pomiarami i kod generujący wykresy.

Ocena:

- Opis sekwencyjnej implementacji - uzasadnienie, że została zaimplementowana optymalnie (2p)
- Wykonanie pomiarów we wszystkich konfiguracjach (5 pkt)
- Sprawozdanie (5 pkt)
- Poprawność metodologiczna (3 pkt)

Zobacz instrukcję i dodaj pracę

Status przesłanego zadania

Status przesłanego zadania	Nie przesłano jeszcze zadania
Stan oceniania	Nieocenione
Pozostały czas	Pozostało 1 dzień 23 godzin
Ostatnio modyfikowane	-
Komentarz do przesłanego zadania	> Komentarze (0)



**AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA
W KRAKOWIE**

AGH

Platforma obsługiwana przez:
Centrum e-Learningu i
Innowacyjnej Dydaktyki AGH
Centrum Rozwiązań
Informatycznych AGH

Pobierz aplikację
mobilną



Wybierz
język

